

1. LR, SVM

1. LR

4. 逻辑回归 (Logistic Regression, LR)

本质是线性回归, 只是在结果前加了一层逻辑函数。
即: 先把特征线性求和, 然后使用函数 $g(z)$ 作为假设函数来预测。

$$g(z) \text{ 为 sigmoid} \Rightarrow g(z) = \frac{1}{1+e^{-z}}$$

$$\Rightarrow g(\theta^T x) = \frac{1}{1+e^{-\theta^T x}}$$

= 分类的损失函数 (交叉熵) | 对数似然损失函数

$$L = \frac{1}{n} \sum_{i=1}^n L(y^{(i)}, \hat{y}^{(i)}) = \frac{1}{n} \sum_{i=1}^n (-y^{(i)} \log(\hat{y}^{(i)}) - (1-y^{(i)}) \log(1-\hat{y}^{(i)}))$$

逻辑回归实现的分类:

使用 softmax 构造模型解决分类。输出值对应于每个类别的概率。

2. SVM 二分类

2.1 原理

5. SVM (Support Vector Machine)

用于解决二分类或伪分类问题。

SVM 的目标是寻找一个最优超平面在空间中分割两类数据, 使离其最近的点到其距离最大化。
而这些点称为支持向量。

2.2 公式推导

5.2 • 划分超平面可通过如下线性方程来描述:

$$w^T x + b = 0$$

样本空间中任意点 x 到超平面 (w, b) 的距离可写为:

$$\gamma = \frac{|w^T x + b|}{\|w\|}$$

假设超平面 (w, b) 能将训练样本正确分类, 有

$$\begin{cases} w^T x_i + b \geq +1, & y_i = +1 \\ w^T x_i + b \leq -1, & y_i = -1 \end{cases} \quad (1)$$

• 两个异类支持向量到超平面的距离之和为: (间隔 margin)

$$\gamma = \frac{2}{\|w\|} \quad (2)$$

• 欲找到具有“最大间隔” (maximum margin) 的划分超平面, 即找到满足 (1) 的 w, b , 使 γ 最大, 即

$$\max_{w, b} \frac{2}{\|w\|}$$

$$\text{s.t. } y_i (w^T x_i + b) \geq 1$$

最大化 $\|w\|$, 等价于最小化 $\|w\|^2$, 优化目标为

$$\begin{cases} \min_{w, b} \frac{1}{2} \|w\|^2 \\ \text{s.t. } y_i (w^T x_i + b) \geq 1 \end{cases}$$

接下来为拉格朗日乘子法转为“对偶问题”求解

2.3 核函数

5.4 核函数

将不可分的数据映射到高维可分 (高斯核, 多项式核...)

什么时候线性核, 什么时候高斯核?

当数据的特征提取地较好, 问题线性可分则可用线性核;

若特征较少, 样本适中, ~~问题线性不可分~~, 问题线性不可分 \Rightarrow 高斯核

$$\begin{array}{l} \text{核函数} \\ \min_{w, b} \frac{1}{2} \|w\|^2 \\ \text{s.t. } y_i (w^T \phi(x_i) + b) \geq 1 \end{array}$$

noteb

2.4 SVM的硬间隔, 软间隔

$\min_{w, b} \frac{1}{2} \ w\ ^2$	$\min_{w, b} \frac{1}{2} \ w\ ^2 + C \sum_{i=1}^m \xi_i$
$\text{s.t. } y^{(i)} (w^T x^{(i)} + b) \geq 1$	$\text{s.t. } y^{(i)} (w^T x^{(i)} + b) \geq 1 - \xi_i$
$\xi_i \geq 0$	$\xi_i \geq 0$
硬间隔	软间隔

软间隔是在硬间隔的基础上引入了松弛变量。(为了防止过拟合)

3. SVM回归

做回归:

分类的 hinge loss

$$\begin{cases} \min_{w,b} \sum ||w||^2 \\ \text{s.t. } y_i(w \cdot \phi(x_i) + b) \geq 1 \end{cases} \quad \begin{array}{l} \text{: 让支持向量间隔更大} \\ \text{: 让样本都正确分类} \end{array}$$

做回归模型: 支持向量之间距离最大不变, 但为条件改变。
回归模型的目标是让训练集中的每个点 (x_i, y_i) 尽量拟合到一个线性模型 $y_i = w \cdot \phi(x_i) + b$

然后, 定义一个量 $\epsilon > 0$, 使 $|y_i - w \cdot \phi(x_i) - b| \leq \epsilon$ 最小

对于某点 (x_i, y_i) , 若 $|y_i - w \cdot \phi(x_i) - b| \leq \epsilon$, 则完全无损失。
若 $|y_i - w \cdot \phi(x_i) - b| > \epsilon$, 则对应的损失为 $|y_i - w \cdot \phi(x_i) - b| - \epsilon$

4. SVM优缺点

缺点: 1) 面对高维数据, 可以使用核函数进行有效处理
2) 使用核函数可以解决非线性分类。

1) SVM 算法对大规模训练样本难以实施

2) 对缺失数据敏感, 对参数和核函数的选择敏感

3) 解决分类问题困难:

经典的 SVM 提出了二分类算法, 而在实际应用中, 需要解决多分类问题, 可以通过多个支持向量机组合来解决。

5. SVM与LR

1) LR 是参数模型, SVM 是非参数模型

2) LR 用的损失函数是 logistical loss, SVM 是 hinge loss.

3) 在学习时, SVM 考虑与分类最相关的少数支持向量点。

LR 的模型相对简单, 在进行大规模线性分类时较为方便。

6. 调参

① SVM

① 分类: `from sklearn.svm import SVC`

`clf = SVC(kernel='linear').fit(X, y)`

调1: 核函数有 "linear", "rbf", "poly" (多项式核)

调2: C 惩罚参数: 默认是 1.0. ($C \uparrow$, 过拟合, $C \downarrow$ 欠拟合)

C 越大, 相当于惩罚松弛变量, 希望松弛变量接近 0, 即对误分类的惩罚增大, 趋向于训练集全对, 但泛化能力弱 (过拟合)

C 越小, 对误分类的惩罚减小, 允许容错, 将他们当成噪点, 泛化能力强。

② 回归: `from sklearn.svm import SVR`